

9/5(월) 고급회계분석

- 중간고사 이후 관련 비용 가지고 토론/실습

- 이론 11-80%, 실습 2-30% (R-studio)

- 데이터를 정하고 수집시간에 따른 내용을 저장해보기 → 기말과제 or 기말시험

- 질문: 메일, 수업시간

- 선수: 선형대수, 일반통계

(주제량, 선량구간, 가설검정)

## Simple Linear Regression

- 교재: 회계분석 (표적독문당)

1 / 28

### 두 변수 사이의 관계

- 대략적 파악 : 산점도(scatter plot)

- 상관분석(correlation analysis)

▶ 두 변수 사이의 상관관계 분석

▶ 확률변수  $X, Y \rightarrow \rho = \text{Corr}(X, Y)$  - 직선적인 관련성 파악

- 회귀분석(regression analysis)

▶ 두 변수 사이의 함수관계를 분석

▶  $x$ : 독립변수 또는 설명변수,  $Y$ : 종속변수 또는 반응변수, 목적변수

회귀

$$Y = f(x) + \varepsilon, \varepsilon: \text{오차항} \rightarrow f(x)?$$

▶ 단순선형회귀분석 - 직선관계를 모형으로 분석

$$(f(x) = a + bx)$$

▶ 중회귀분석 - 두 개 이상의 설명변수 사용

$$(f(x) = a + b_1x_1 + \dots + b_kx_k)$$

확률변수, 확률변수  
X: 분포: Pdf (pmf)  
E(X), Var(X)

XY → Pdf  
Joint  
E(X), E(Y), Var(X), Var(Y)

$$\text{COV}(X, Y)$$

$$\downarrow$$
  
$$\text{Corr}(X, Y)$$

2 / 28

## Example




Figure: 아버지의 키(fheight)와 아들 키(sheight)간의 회귀직선

3 / 28

## 회귀분석의 기본개념

$n$ : sample size (표본크기)

### - 자료구조

- 자료구조 :  $(x_1, Y_1), \dots, (x_n, Y_n)$
- $(x_1, \dots, x_n)$  : 설명변수 (explanatory variable) (또는 독립변수): 상수(숫자)  
두 변수가 있을 때, 다른 한 변수에 영향을 주는 변수
- $(Y_1, \dots, Y_n)$  : 반응변수 (response variable) (또는 종속변수): 목표변수 (target)  
두 변수가 있을 때, 다른 한 변수에 영향을 받는 변수
- 관측값 :  $(x_1, y_1), \dots, (x_n, y_n)$


4 / 28

## Example

$n$	$x$	$y$			
상점번호	광고료	총판매액	상점번호	광고료	총판매액
1	4	9	6	12	30
2	8	20	7	6	18
3	9	22	8	10	25
4	8	15	9	6	10
5	8	17	10	9	20

Table: 표본상점의 광고료(단위:10만원)와 총판매액(단위:100만원)

5 / 28



기본 가정



$X$ 가 주어졌을 때  $Y$ 의 기대값은 일차함수 관계일 것이다.

- Linearity (선형성) :  $E(Y|X = x) = \mu_{y \cdot x} = \beta_0 + \beta_1 x$  일차함수관계
- Homoscedastic (등분산성) :  $Var(Y|X = x) = \sigma^2$  분산은  $x$ 값과 상관없다.
- Normality (정규성) :  $Y|X = x \sim N(E(Y|X = x), \sigma^2)$
- Independency (독립성) :  $\epsilon$ 's are mutually independent

$$\mu + \text{오차} = y$$

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \text{ 서로 독립}$$

6 / 28

## Example




Figure: 광고료와 총판매액의 산점도

산점도를 통해 선형관계 파악  
→ 선형회귀분석 이용

7 / 28

## 단순선형회귀 모형

### Model

IID (Independent)  
 $\epsilon_i \sim N(0, \sigma^2)$

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

- $(\epsilon_1, \dots, \epsilon_n)$  : 오차항(random error)  
서로 독립이면서 평균이 0, 분산이  $\sigma^2$  인 확률 변수
- 회귀계수(regression coefficient) (or 모수, parameter)
  - ▷  $\beta_0$  : 상수항 또는 절편 (constant coefficient or intercept)
  - ▷  $\beta_1$  : 기울기 (slope)
- 회귀직선, 회귀선 :  $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 
  - ▷  $\hat{\beta}_0, \hat{\beta}_1, \hat{y}$  : estimate of  $\beta_0, \beta_1, E(Y|X=x)$

부주정값  
노 hat  
기대값에 대한 추정

$$y|X=x \sim N(\quad, \sigma^2)$$

$$\epsilon_i = y_i - (\beta_0 + \beta_1 x_i)$$

$$X \sim N(\mu_x, \sigma^2)$$

$$\Rightarrow aX + b \sim N(a\mu_x + b, a^2\sigma^2)$$

a, b 상수

$$\epsilon_i \sim N(0, \sigma^2)$$

8 / 28



① 상정도

② 모형가정:  $y = \beta_0 + \beta_1 x + \varepsilon_i$ ,  $\varepsilon_i \sim N(0, \sigma^2)$ , iid

1) 추정:  $\hat{\beta}_0, \hat{\beta}_1, \hat{\sigma}^2$

추정방법: LSE

Example - 회귀직선의 비교

2) 추론 (가설검정)

(→ 회귀계수의 유의성 검정 (F검정) -  $H_0: \beta_1 = 0$ )

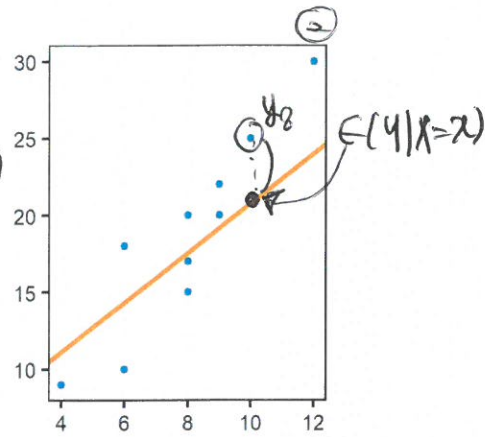
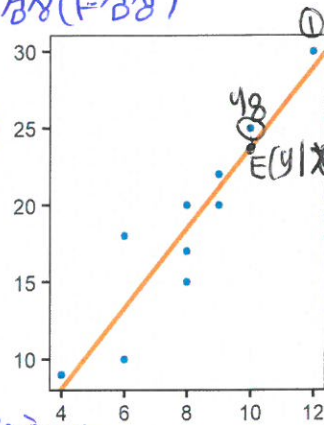
1. 회귀계수  
유의성 검정 (t검정)

$H_0: \beta_0 = \beta'_0 (=0)$

$H_1: \beta_1 = \beta'_1 (=0)$

3) 적합도 측정:  $R^2$

4) 회귀면당, 오차항의 개수  
등분




$$E(y) = \mu_{y,x}$$

$$= \beta_0 + \beta_1 x$$

$$y \sim N(\mu_{y,x}, \sigma^2)$$

선형성



정규성  
등분산성

\* 독립성

9 / 28

## Least Square Estimation (LSE)

- 오차제곱합

$$S = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n \{y_i - (\beta_0 + \beta_1 x_i)\}^2$$

- 최소제곱추정량(LSE)

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1 \in \mathbb{R}} \sum_{i=1}^n \{y_i - (\beta_0 + \beta_1 x_i)\}^2$$

예.  $\beta$  minimize S  
( $\beta_0, \beta_1$ )

- Least square fit:  $\hat{y} (\equiv E(Y|X=x)) = \hat{\beta}_0 + \hat{\beta}_1 x$

회귀식

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

$$\varepsilon_i = y_i - (\beta_0 + \beta_1 x_i)$$

$$= E(y_i | X=x_i)$$

$$\begin{aligned} & \rightarrow E(y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2 \\ & = E \epsilon_i^2 \end{aligned}$$

10 / 28



정규방정식

$x_i$ 와  $y_i$ 는  
중복해서 넣어야

$$S = \sum (y_i - \beta_1 x_i)^2$$

$$= \sum (y_i^2 - 2\beta_1 y_i x_i + \beta_1^2 x_i^2)$$

Least Square Estimation (LSE)

$$= (\sum x_i^2) \beta_1^2 + (\sum y_i x_i) \beta_1 + \sum y_i^2$$

■ 정규방정식 (normal equation)

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$S = \sum (y_i - \beta_0 - \beta_1 x_i)^2$$

$$\frac{\partial S}{\partial \beta_0} = \sum 2(y_i - \beta_0 - \beta_1 x_i)(-1)$$

11 / 28

Least Square Estimation (LSE)

■ 최소제곱추정량 = 정규방정식의 해

$$(1) \sum y_i - \sum \hat{\beta}_0 - \sum \hat{\beta}_1 x_i = 0$$

$$= \sum y_i - n \hat{\beta}_0 - \hat{\beta}_1 \sum x_i = 0$$

$$\begin{cases} -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 & (1) \\ -2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 & (2) \end{cases}$$

$$(2) \sum x_i y_i - \sum \hat{\beta}_0 x_i - \sum \hat{\beta}_1 x_i^2 = 0$$

$$= \sum x_i y_i - \hat{\beta}_0 \sum x_i - \hat{\beta}_1 \sum x_i^2 = 0$$

$$\Rightarrow \begin{cases} n \hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i \\ \hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i \end{cases}$$

12 / 28

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$n\hat{\beta}_0 = \sum y_i - \hat{\beta}_1 \sum x_i$$

$$\hat{\beta}_0 = \frac{1}{n} \sum y_i - \hat{\beta}_1 \frac{1}{n} \sum x_i$$

$$= \bar{y} - \hat{\beta}_1 \bar{x}$$

$$(2) \text{식 } \sum x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\sum x_i (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)$$

$$= \underbrace{\sum x_i (y_i - \bar{y})}_{\textcircled{1}} - \underbrace{\sum x_i \hat{\beta}_1 (x_i - \bar{x})}_{\textcircled{2}} = 0$$

$$\textcircled{1} \sum (x_i - \bar{x} + \bar{x})(y_i - \bar{y})$$

$$= \sum (x_i - \bar{x})(y_i - \bar{y}) + \sum \bar{x}(y_i - \bar{y})$$

$$= \sum_{\text{un}} (xy)$$

x편차와  
y편차곱의합 ↑

$$\textcircled{2} = \hat{\beta}_1 \sum x_i (x_i - \bar{x})$$

$$= \hat{\beta}_1 \sum (x_i - \bar{x} + \bar{x})(x_i - \bar{x})$$

$$= \hat{\beta}_1 ( \sum (x_i - \bar{x})(x_i - \bar{x}) + \sum \bar{x}(x_i - \bar{x}) )$$

$$= \hat{\beta}_1 \sum (x_i - \bar{x})^2$$

$$= \hat{\beta}_1 S_{xx}$$

$$\Rightarrow S_{xy} - \hat{\beta}_1 S_{xx} = 0$$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}$$

$$x_i - \bar{x}: \text{편차}$$

$$\sum (x_i - \bar{x}) = 0$$

pf) ~~xx~~

$$\sum x_i - \sum \bar{x}$$

$$= \sum x_i - n \cdot \bar{x}$$

$$= \sum x_i - \frac{1}{n} \sum x_i \cdot n$$

$$= 0$$

## Least Square Estimation (LSE)

### ■ 최소제곱추정량(LSE)

$$\begin{cases} \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}} \\ \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \end{cases}$$

$$\bullet \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

13 / 28

### Example - LSE

과제비 (만원)		판매액 (만원)		S <sub>xx</sub> (만원 <sup>2</sup> )		S <sub>xy</sub> (만원 <sup>2</sup> )	
i	x <sub>i</sub>	y <sub>i</sub>	x <sub>i</sub> - $\bar{x}$	y <sub>i</sub> - $\bar{y}$	(x <sub>i</sub> - $\bar{x}$ ) <sup>2</sup>	(y <sub>i</sub> - $\bar{y}$ ) <sup>2</sup>	(x <sub>i</sub> - $\bar{x}$ )(y <sub>i</sub> - $\bar{y}$ )
1	4.00	9.00	-4.00	-9.60	16.00	92.16	38.40
2	8.00	20.00	0.00	1.40	0.00	1.96	0.00
3	9.00	22.00	1.00	3.40	1.00	11.56	3.40
4	8.00	15.00	0.00	-3.60	0.00	12.96	-0.00
5	8.00	17.00	0.00	-1.60	0.00	2.56	-0.00
6	12.00	30.00	4.00	11.40	16.00	129.96	45.60
7	6.00	18.00	-2.00	-0.60	4.00	0.36	1.20
8	10.00	25.00	2.00	6.40	4.00	40.96	12.80
9	6.00	10.00	-2.00	-8.60	4.00	73.96	17.20
10	9.00	20.00	1.00	1.40	1.00	1.96	1.40
sum	80	186	0	0	46	368.4	120
$\bar{x} = 8$		$\bar{y} = 18.6$		S <sub>xx</sub>		S <sub>xy</sub>	

14 / 28




## Example - LSE

- 최소제곱추정량 (LSE)

$$\hat{\beta}_1 = \frac{120}{46} = 2.6087,$$

$$\hat{\beta}_0 = 18.6 - 2.6087 \times 8 = -2.2696$$



- 추정된 회귀직선: Least square fit

$$\hat{y} = \underbrace{-2.2696}_{\beta_0} + \underbrace{2.6087}_{\beta_1} \cdot x$$

기울기 =  $\frac{\Delta y}{\Delta x}$ :  $x$ 가 1단위 증가할 때  $y$ 의 변화량  
( $\beta_1$ )

$\therefore$  광고비가 100만원 증가하면  
( $x$ )  
평균매출은 2,608,700원(백만원) 증가한다.  
 $\approx$  260만

15 / 28

## Properties of fitted regression line

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + \varepsilon_i$$



$$\hat{y}_i = E(y_i | X = x_i)$$

\*편차:  $x_i - \bar{x}$

예:  $\mu - \hat{\mu}$  실제값과 추정값의 차이 (모수에서)

잔차:  $y_i - \hat{y}_i$

오차항의 추정량

잔차 (residual):  $e_i = y_i - \hat{y}_i, i = 1, 2, \dots, n$

(1) 잔차의 합은 0이다. ( $\sum_{i=1}^n e_i = 0$ ) 12page

(2)  $\sum_{i=1}^n e_i^2$  은 최소값을 갖는다. 10page

(3) 잔차의  $x_i$ 에 의한 가중합은 0이다. ( $\sum_{i=1}^n x_i e_i = 0$ ) 12page

(4) 잔차의  $\hat{y}_i$ 에 의한 가중합은 0이다. ( $\sum_{i=1}^n \hat{y}_i e_i = 0$ )

(5)  $(\bar{x}, \bar{y})$ 는 적합된 회귀직선 위에 있다.

$$e_i = \varepsilon_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

실제값과 추정된 회귀직선의 차이 (잔차)

$$= E(\hat{\beta}_0 + \hat{\beta}_1 x_i) e_i$$

$$= \varepsilon \hat{\beta}_0 e_i + \varepsilon \hat{\beta}_1 x_i e_i$$


$$= \hat{\beta}_0 \varepsilon e_i + \hat{\beta}_1 \varepsilon x_i e_i$$

(1)에서  $\varepsilon = 0$  (3)에서  $\varepsilon = 0$

$$= 0$$



## Example



17 / 28

$x_1, x_2, \dots, x_n \sim N(\mu, \sigma^2)$  일때

$$\hat{\mu} = \frac{1}{n} \sum x_i$$

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2 \quad \text{Estimation of error variance}$$

\* 불편추정량 : 오차  $\rightarrow \hat{\sigma}$   
(unbiased estimate)

$$\Rightarrow E(\hat{\sigma}) = \sigma$$

■ 오차분산 ( $\sigma^2$ )의 추정:

\*  $E(\hat{\mu}) = \mu$  (정확제곱특성) 잔차(오차) 제곱합 (residual (or error) sum of squares):

$$E(\hat{\sigma}^2) = \sigma^2 \quad (\text{카이제곱})$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2$$

• 평균제곱오차 (mean squared error) :  $MSE = \frac{SSE}{n-2}$

• 오차분산의 추정값  $\hat{\sigma}^2 = MSE$

$$y = \beta_0 + \beta_1 x + \varepsilon_i$$

$$\varepsilon_i \sim N(0, \sigma^2) \quad \text{IID}$$

주장해야함

$$e_1, e_2, \dots, e_n$$

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum (e_i - \bar{e})^2$$

$$(\bar{e} = \frac{1}{n} \sum e_i = 0)$$

$$= \frac{1}{n-2} \sum e_i^2 = \frac{1}{n-2} \sum (y_i - \hat{y}_i)^2$$

(제약조건에 의해 자유도 2개가 빠짐)

$$\begin{pmatrix} \sum e_i = 0 \\ \sum x_i e_i = 0 \end{pmatrix}$$

18 / 28

## Decomposition of deviations

### ■ 총편차의 분해

- $y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}), \forall i$
- 총편차(total deviation) =  $y_i - \bar{y}$
- 추측값의 편차 =  $(\hat{y}_i - \bar{y}) = (\hat{y}_i - \bar{y})$

$\Rightarrow$  총편차 = 잔차<sup>2</sup> + 추측값의 편차<sup>2</sup>  
 부호 중요! 절대값!

19 / 28

## Decomposition of deviations


가설은 때,



$$E(y_i) = \mu$$

$$\hat{\mu} = \bar{y}$$


Figure: 편차의 분해



20 / 28

## Decomposition of deviations

Figure: 편차의 분해



모형적합이 잘 된다는 뜻은?

→ 잔차는 작게, 회귀모형에 의해 설명되는 부분은 크게

21 / 28

## Decomposition of sum of squares

■ 제곱합의 분해 :  $SST = SSE + SSR$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

제곱합의 종류	정의 및 기호
총제곱합 (total sum of squares)	$SST = \sum_{i=1}^n (y_i - \bar{y})^2$
잔차제곱합 (residual sum of squares) (error)	$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ ↓
회귀제곱합 (regression sum of squares)	$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ ↑

22 / 28



편차  $y_i - \bar{y} = \underbrace{(y_i - \hat{y}_i)} + \underbrace{(\hat{y}_i - \bar{y})}$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum (y_i - \hat{y}_i + \hat{y}_i - \bar{y})^2$$

$$= \sum \left( (y_i - \hat{y}_i)^2 + (\hat{y}_i - \bar{y})^2 + 2(y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) \right)$$

$$= \sum (y_i - \hat{y}_i)^2 + \sum (\hat{y}_i - \bar{y})^2 + \underbrace{2 \sum (y_i - \hat{y}_i)(\hat{y}_i - \bar{y})}$$

$$= \sum e_i (\hat{y}_i - \bar{y})$$

$$= \sum e_i \hat{y}_i - \sum \bar{y} \cdot e_i$$

by (4) !!       $\sum e_i = 0$

$$\therefore \boxed{\sum (y_i - \bar{y})^2 = \sum (y_i - \hat{y}_i)^2 + \sum (\hat{y}_i - \bar{y})^2}$$

SST  
총제곱합

SSE  
잔차제곱합

SSR  
회귀제곱합

(잔차 =  $e_i$ )  
Residual

## Coefficient of determination

### ■ 결정계수 (Coefficient of determination)

- 정의 :  $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$
- 의미 : 회귀직선의 기여율  
(총변동 가운데 회귀직선으로 설명되는 변동의 비율)
- 성질
  - $0 \leq R^2 \leq 1$
  - $R^2$  값이 1에 가까울수록 회귀에 의한 설명이 잘 됨을 뜻함
  - $R^2 = r^2$  ( $r$  : sample correlation)  
(단순선형회귀모형에서만 성립)

$R^2$ 은 비교할때 사용 (상대적임)  
Model 1 80%, Model 2 75%인대

23 / 28

## 상관분석

- $X, Y$  : random variables
- 모상관계수 (population coefficient of correlation)  

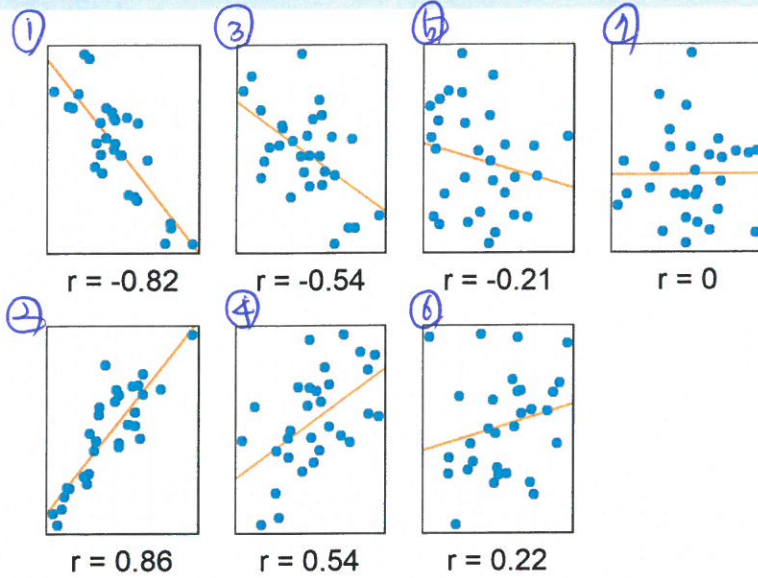
$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} := \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$
- $(x_1, y_1), \dots, (x_n, y_n)$  : sample
- 표본상관계수 (sample coefficient of correlation)  

$$\hat{\rho}_{XY} = r_{xy} = \frac{S_{(xy)}}{\sqrt{S_{(xx)}S_{(yy)}}}$$
- $-1 \leq \rho \leq 1, -1 \leq r_{xy} \leq 1$

$\rho > 0$  : 양의 상관관계  
 $\rho < 0$  : 음의 상관관계  
 $\rho \approx 0$  : 상관관계가 없다.

$$\begin{aligned} S_x^2 &= \frac{1}{n-1} \sum (x_i - \bar{x})^2 \\ &= \frac{1}{n-1} S_{(xx)} \\ S_y^2 &= \frac{1}{n-1} S_{(yy)} \\ \text{Cov}(X, Y) &= \sigma_{XY} \\ &= E(X - \mu_X)(Y - \mu_Y) \\ \Rightarrow \sigma_{XY} &= \frac{1}{n-1} \sum (x_i - \bar{x})(y_i - \bar{y}) \\ &= \frac{1}{n-1} S_{(xy)} \end{aligned}$$

## 표본상관계수와 산점도



①, ② 상관관계가 강한 case

25 / 28

## Example

### ■ 광고료와 총판매액

#### • 표본상관계수

$$r_{xy} = \frac{S_{(xy)}}{\sqrt{S_{(xx)}S_{(yy)}}} = \frac{120}{\sqrt{46 \times 368.4}} = 0.92$$

(아이가음.  
상관관계가 크다.

26 / 28

## 표본상관계수와 단순선형회귀모형

\*\*\*  
■ 단순선형회귀모형에서는

- 표본상관계수와 결정계수

$$R^2 = r_{xy}^2$$

- 표본상관계수와 회귀직선의 기울기

$$r_{xy} = \hat{\beta}_1 \frac{s_x}{s_y}$$

$s_x, s_y$  : 표본표준편차 (sample standard deviation)

$$s_x = \sqrt{\frac{S_{(xx)}}{n-1}}, \quad s_y = \sqrt{\frac{S_{(yy)}}{n-1}}$$

$$\hat{\beta}_1 = \begin{cases} \oplus & r_{xy} \uparrow \\ \ominus & r_{xy} \downarrow \end{cases}$$

$$R^2 = \frac{SSR}{SST} = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2} = \frac{S^2_{(xy)}}{S_{(yy)} S_{(xx)}} = r_{xy}^2$$

$$\begin{aligned} SSR &= \sum (\hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{y})^2 \\ &= \sum (\cancel{\bar{y}} - \hat{\beta}_1 \bar{x} + \hat{\beta}_1 x_i - \cancel{\bar{y}})^2 \\ &= \sum \hat{\beta}_1^2 (x_i - \bar{x})^2 \\ &= \hat{\beta}_1^2 \sum (x_i - \bar{x})^2 \\ &= \left( \hat{\beta}_1 = \frac{S_{(xy)}}{S_{(xx)}} \right)^2 \sum (x_i - \bar{x})^2 \\ &= \frac{S^2_{(xy)}}{S_{(xx)}} \end{aligned}$$

27 / 28


## 분산분석

\*\*\*  
■ 단순회귀직선의 유의성 검정을 위한 분산분석표

요인	제곱합(SS)	자유도(df)	평균제곱(MS)	$F_0$	유의확률
회귀	SSR	1	$MSR = \frac{SSR}{1}$	$\frac{MSR}{MSE} \uparrow$	$P(F \geq F_0)$
잔차	SSE	$n-2$	$MSE = \frac{SSE}{n-2}$		
계	SST	$n-1$			

$$SST = SSR + SSE$$

↑ 커야 좋음



$F_0$  값이 큰 값일수록 유의확률이 작아진다.

$F_0 \uparrow$  : 동계적으로 유의하다.

- $F \sim F(1, n-2)$  보와 보의 자유도
- $F_0 > F(1, n-2; \alpha) \Rightarrow$  유의수준  $\alpha$  하에서, 회귀선이 유의함.

28 / 28